

1. L'information statistique

Nature et présentation

Sam Gyetvay

ECO 2273 – Économétrie I

September 5, 2025

- ▶ Introduction
- ▶ Bref historique des données et de la statistique
- ▶ Qu'est-ce que les données ?
- ▶ Types de variables
- ▶ D'où viennent les données ?
- ▶ Exemples de bases de données
- ▶ Visualisation des données

Introduction

Professeur

Sam Gyetvay

Économiste du travail

Recherche principalement sur l'immigration

Nouveau prof dans le département (arrivé août 2025)

PhD UBC 2024, Postdoc Ohio State 2024-25

Première fois que j'enseigne

Je suis un anglophone montréalais, j'étais autrefois bilingue fluide mais mon français est maintenant rouillé

Auxiliaire d'enseignement

Oumar Djamaldiev

Étudiant MA en économie UQAM-ESG

Responsable de la démonstration lundi 14h00-15h00, où il enseignera STATA

Le nom du cours est Économétrie I, mais nous n'apprendrons pas beaucoup d'économétrie *à proprement parler* ce semestre

Nous allons plutôt construire une base de connaissances sur laquelle l'économétrie pourra se développer

$$\begin{aligned}\text{Économétrie} &= \textbf{Probabilités} \\ &+ \textbf{Statistiques} \\ &+ \text{Algèbre linéaire} \\ &+ \text{Théorie économique}\end{aligned}$$

Notre base se concentrera sur les deux premiers

Les prochaines conférences se concentreront sur les probabilités. Dans cette introduction, nous présentons quelques concepts de base des données et de la statistique

Statistique

- ▶ Latin *statisticum collegium* (« conseil de l'État »)
- ▶ Italien *statista* (« homme d'État »)
- ▶ Allemand *statistik* (« science de l'État »)

Données

- ▶ Latin *data / datum* (« choses supposées être des faits »)

Histoire de la statistique

Comme le montre son étymologie, l'origine de la statistique est étroitement liée à l'émergence des États centralisés.

Les États collectaient des informations systématiques pour connaître leur population et leur territoire

- ▶ Recensement de la population
- ▶ Comptes nationaux
- ▶ Relevés de température

Le produit de cette collecte systématique d'informations s'appelle **données**

Au cours de plusieurs siècles, des méthodes mathématiques ont été développées pour appliquer la **théorie des probabilités** aux données afin d'obtenir des enseignements. La **statistique** désigne cet ensemble de connaissances.

Dynastie Ming "Livre jaune" (1422)



Livre jaune des impôts et services de travail
Source : <https://iguoxue.ifeng.com/51700719/>

Premier recensement canadien, 1871

[illegible]

Page de retour du recensement d'Ascot, Québec, 1871

394	CENSUS OF 1871.	RECRUITMENT DE 1871.	395																
FRANCE EDWARD ISLAND.										ISLE DU PRINCE-ÉDOUARD.									
TABLE IV.—North Places of the People.										TABLE V.—Lancs and Caths.									
TABLEAU IV.—Population par Lieu de Naissance.										TABLEAU V.—Ternes et Batail.									
Counties. Comtés.	English Anglais.	French- Canadians. Français.	Ireland Irlandais.	Scottish Écossais.	Natives, Natijs.	British Colonists. Colonies Britanniques.	Other Countries. Autres Pays.	Not given. Non donnés.	Total.	Counties. Comtés.	Number of Companies. Nombre de Compagnies.	Lancs.—Ternes. Total recruited. Total recrutés.	Caths.—Batail. Total recruited. Total recrutés.	Caths.—Batail. Total recruited. Total recrutés.					
1st District.	3,823	119	335	76	1,365	32	203	14	59	1st.	1,394	16,502	15,710	2,778					
2nd do.	4,729	147	307	77	9,963	329	341	8	114	2nd.	658	65,129	12,742	707					
3rd do.	5,230	225	66	67	4,989	505	329	7	26	3rd.	719	64,774	10,339	1,067					
4th do.	6,455	100	362	142	5,559	29	501	14	29	4th.	827	85,355	10,627	4,584					
5th do.	3,582	74	62	38	3,077	1	241	20	1	5th.	146	33,182	7,231	1,139					
Total.	26,202	504	801	419	24,321	1,238	1,847	73	239	Total.	2,427	238,481	164,717	12,301					
1st District.	5,942	150	359	794	5,028		329	39		1st.	1,392	139,397	49,403	1,232					
2nd do.	5,405	399	231	386	4,538	35	40	11	26	2nd.	1,359	105,213	10,919	4,319					
3rd do.	4,012	294	125	125	4,499	29	58	7	39	3rd.	1,063	100,617	10,828	2,250					
4th do.	6,291	74	241	777	4,633	14	377	18	14	4th.	1,211	105,760	10,631	1,274					
Charlottetown.	8,907	413	624	246	777		745	103		Charlottetown.	70	214	5,622	640					
Total.	45,651	1,062	1,539	2,259	19,465	77	1,369	806	77	Total.	4,759	466,271	205,460	25,469					
1st District.	5,714	30	108	229	7,421	4	364	87	4	1st.	732	73,012	15,495	36					
2nd do.	5,199	48	136	127	7,499		393	38		2nd.	659	72,891	15,439	137					
3rd do.	5,506	136	254	411	5,971		586	39		3rd.	707	79,779	20,390	467					
4th do.	5,992	121	148	626	7,996	4	349	31	4	4th.	848	65,463	25,169	249					
Georgetown.	5,000	13	41	46	4,597		179	8		Georgetown.	99	5,612	1,195	94					
Total.	25,569	289	746	1,531	20,584	8	976	165	8	Total.	3,268	235,649	39,773	1,673					
Grand Total.	94,821	1,907	2,712	4,793	79,968	323	3,246	394	323	Grand Total.	31,812	1,085,700	643,580	32,502					

Tableau imprimé contenant des statistiques sur le lieu de naissance des individus à l'Î.-P.-É., la superficie de terres et le bétail possédés

John Graunt *Natural and Political Observations Made upon the Bills of Mortality (1662)*

Collecte et analyse des Bills of Mortality de Londres et des registres de baptêmes paroissiaux (naissances)

Utilisation des registres de baptême et d'enterrement pour estimer la population

Construction d'une table de vie :

- Probabilité de survie par âge
- Forte mortalité infantile et déclin régulier ensuite

Age.	Per-	Age.	Per-	Age.	Per-	Age.	Per-	Age.	Per-	Age.	Per-	Age.	Per-	Age.	Per-
Curt.	fons.	Curt.	fons	Curt.	fons	Curt.	fons	Curt.	fons	Curt.	fons	Curt.	fons	Curt.	fons.
1	1000	8	680	15	628	22	585	29	539	36	481	7	5547		
2	855	9	670	16	622	23	579	30	531	37	472	14	4584		
3	798	10	661	17	616	24	573	31	523	38	463	21	4270		
4	760	11	653	18	610	25	567	32	515	39	454	28	3564		
5	732	12	646	19	604	26	560	33	507	40	445	35	3604		
6	710	13	640	20	598	27	553	34	499	41	436	42	3178		
7	692	14	634	21	592	28	546	35	490	42	427	49	2709		
												56	2194		
												63	1694		
												70	1264		
43	417	50	346	57	272	64	202	71	131	78	58	77	692		
44	407	51	335	58	262	65	192	72	120	79	49	84	253		
45	397	52	324	59	252	66	182	73	109	80	41	100	107		
46	387	53	313	60	242	67	172	74	98	81	34				
47	377	54	302	61	232	68	162	75	88	82	28				
48	367	55	292	62	222	69	152	76	78	83	23				
49	357	56	282	63	212	70	142	77	68	84	20				
													34000		
													Sum Total.		

Les données à l'ère moderne

Aujourd'hui, les données proviennent de nombreuses sources

Sondages: recueillent des opinions ou des informations sur la population

- ▶ *L'Enquête sur la population active* utilisée pour calculer le taux de chômage

Expérimentations: études contrôlées pour identifier des effets causaux

- ▶ Les essais de Pfizer pour un vaccin contre la COVID-19 recueillent des données sur les participants à l'étude

Données administratives: collectées dans le cadre des opérations gouvernementales

- ▶ Les dossiers fiscaux basés sur le T1, T4

Données en ligne: générées par les plateformes numériques

- ▶ Les données d'Amazon sur chaque transaction et avis produit

La disponibilité de ces sources de données a transformé la recherche en économie

Qu'est-ce qu'une base de données ?

Les données sont des faits

- ▶ Sam est un homme de 34 ans né à Montréal, Canada
- ▶ La population du Québec en 2015 était de 8,25 M

Avant d'appliquer la statistique à des données, celles-ci doivent être organisées en **base de données**

Une base de données est une manière de collecter un ensemble de faits dans une **matrice** ou un **tableau**

Chaque ligne représente une **observation**

Chaque colonne représente une **variable** différente

Exemple d'une base de données 1

Nom	Sexe	Âge	Lieu de naissance	Éducation
Sam	M	34	Montréal, Canada	PhD
Alex	M	29	Toronto, Canada	BA
Marie	F	31	Québec, Canada	MA

Chaque ligne = une observation (personne)

Chaque colonne = une variable (Nom, Sexe, Âge, Lieu de naissance, Éducation)

La première ligne n'est pas une observation, elle donne seulement les noms des variables

Exemple d'un base de données 2

Année	Province	Population
1985	Québec	6,665,800
1990	Québec	6,997,000
1995	Québec	7,219,200
2000	Québec	7,357,000
2005	Québec	7,581,200
2010	Québec	7,929,400
2015	Québec	8,254,900

Chaque ligne = une observation (année-province)

Chaque colonne = une variable (Année, Province, Population)

Types de variables

Comme nous l'avons déjà vu, il existe différents types de variables.

Certaines variables sont **numériques**, comme la population, l'âge ou l'année.

Certaines variables sont **non numériques**, comme le nom, le sexe, la province, le lieu de naissance ou le niveau d'éducation.

Parfois, les variables non numériques ont un **ordre**. Par exemple, on peut classer les niveaux d'éducation : PhD > MA > BA.

Certaines variables non numériques n'ont pas d'ordre ; elles représentent juste différentes catégories. Nom, sexe, lieu de naissance, province sont ainsi.

Visualisation des données

La plupart des bases de données sont assez grands : ils contiennent des centaines, des milliers, parfois des millions de lignes.

Il n'est donc pas pratique de lire un base de données ligne par ligne.

La visualisation des données transforme les données en image. Ces images sont faciles à interpréter et peuvent révéler des motifs intéressants dans les données.

Aujourd'hui, nous discuterons de trois visualisations classiques, bien que beaucoup d'autres existent

1. Séries temporelles
2. Nuage de points
3. Histogram

Séries temporelles


Un graphique en séries temporelles montre comment une variable change dans le temps.

On ne peut utiliser les séries temporelles que si la base de données contient une variable temporelle comme l'année, le trimestre, le mois ou la date.


Dans un graphique en séries temporelles, la variable temps (ex. année) est sur l'axe X, et l'autre variable sur l'axe Y.

Les valeurs à gauche sont plus anciennes, et celles à droite plus récentes.


Population du Québec, 1926-2016



Taux d'urbanisation du Québec, 1925-2016



Taux de chômage du Québec, 1950-2016



Nuage de points

Un nuage de points montre comment deux variables sont liées, généralement à un instant donné.

Un nuage de points a une variable sur l'axe Y et une sur l'axe X.

On place ensuite un point à la coordonnée (y, x) correspondant à chaque observation.


Nuage de points

Un nuage de points montre comment deux variables sont liées, généralement à un instant donné.

Un nuage de points a une variable sur l'axe Y et une sur l'axe X.

On place ensuite un point à la coordonnée (y, x) correspondant à chaque observation.

Nom	Âge	Revenu
Alice	25	58




Nuage de points

Un nuage de points montre comment deux variables sont liées, généralement à un instant donné.

Un nuage de points a une variable sur l'axe Y et une sur l'axe X.

On place ensuite un point à la coordonnée (y, x) correspondant à chaque observation.

Nom	Âge	Revenu
Alice	25	58
Bob	45	67




Nuage de points

Un nuage de points montre comment deux variables sont liées, généralement à un instant donné.


Un nuage de points a une variable sur l'axe Y et une sur l'axe X.

On place ensuite un point à la coordonnée (y, x) correspondant à chaque observation.

Nom	Âge	Revenu
Alice	25	58
Bob	45	67
Carol	55	61
Dave	65	74
Eve	70	76



Nuage de points : taux de chômage et revenu par habitant, 2016



Nuage de points : notes des étudiants dans deux cours



Histogramme

Un histogramme montre la fréquence à laquelle chaque valeur d'une variable apparaît dans les données.

- ▶ Axe X : valeurs de la variable
- ▶ Axe Y : nombre de fois que la valeur apparaît dans les données

Par exemple, si la variable est une note d'examen, la hauteur de chaque barre montre combien d'étudiants ont obtenu cette note.


- ▶ Si 9 étudiants ont obtenu la note de 80, l'histogramme place une barre de hauteur 9 à 80

Parfois, on regroupe des valeurs proches en **classes**.


La **largeur de classe** détermine la largeur de chaque regroupement

- ▶ Si la largeur de classe = 3, on peut regrouper les notes 80, 81, 82 ensemble

Histogramme : distribution des notes dans une classe



Histogramme : distribution des notes dans une classe (largeur de classe = 3)



Caractéristiques d'une distribution

Comment décririez-vous la distribution des notes dans cette classe ?

En mots, on pourrait décrire


1. la tendance centrale

- ▶ La plupart obtiennent une note proche de 75

2. la dispersion

- ▶ Certains obtiennent une note > 90
- ▶ Certains obtiennent une note < 60

Comment être plus précis ?



Résumé des données avec statistiques descriptives

Une autre façon d'analyser rapidement les données est de calculer les **statistiques descriptives**.

Certaines statistiques, comme la **moyenne**, la **médiane** et le **mode**, renseignent sur la **tendance centrale** d'une variable.

- ▶ Quelle est la valeur typique ou centrale de la variable ?

D'autres, comme la **variance**, l'**écart-type** ou l'**intervalle interquartile**, renseignent sur la dispersion de la variable.

- ▶ Quelle est l'étendue des valeurs ?
- ▶ La variable prend-elle souvent des valeurs extrêmes ou reste-t-elle dans un intervalle étroit ?

Notation vectorielle

Nous ferons souvent référence à une colonne d'un ensemble de données par un **vecteur** x

$$x = (x_1, x_2, \dots, x_n)$$

x_i : valeur de x dans la i -ème ligne de l'ensemble de données

n : nombre de lignes dans l'ensemble de données

La **somme** des éléments de x s'écrit $\sum_{i=1}^n x_i = x_1 + x_2 + \dots + x_n$.

Dans l'ensemble de données ci-dessous $n = 3$ et nous pourrions écrire l'âge comme $x = (x_1, x_2, x_3) = (34, 29, 31)$

Nom	Sexe	Âge	Lieu de naissance	Éducation
Sam	M	34	Montréal, Canada	PhD
Alex	M	29	Toronto, Canada	BA
Marie	F	31	Québec, Canada	MA

$$\sum_{i=1}^n x_i = \sum_{i=1}^3 x_i = x_1 + x_2 + x_3 = 34 + 29 + 31 = 94$$

Mesures de tendance centrale

La tendance centrale décrit la **valeur typique** d'une variable.

Trois mesures courantes :

- ▶ **Moyenne** — moyenne arithmétique
- ▶ **Médiane** — valeur du milieu une fois triée
- ▶ **Mode** — valeur la plus fréquente

Calculer moyenne, médiane et mode

Moyenne (arithmétique)

La moyenne d'une variable $x_1, x_2, \dots, x_n$ est

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Médiane (valeur centrale)

- ▶ Trier les données par ordre croissant.
- ▶ Si n est impair : valeur centrale.
- ▶ Si n est pair : moyenne des deux valeurs centrales.

Mode (valeur la plus fréquente)

- ▶ Valeur apparaissant le plus souvent.
- ▶ Si aucune répétition → pas de mode.

Exemple : calculer moyenne, médiane, mode

Nom	Âge
Alice	25
Bob	45
Carol	55
Dave	65
Eve	70
Fran	70

Moyenne : $(25 + 45 + 55 + 65 + 70 + 70)/6 = 55$

Médiane : valeur centrale = $(55 + 65)/2 = 60$

Mode : 70 apparaît deux fois, toutes les autres valeurs une fois

Mesures de dispersion

La dispersion décrit à quel point les données sont **étalées**.

Mesures courantes :

- ▶ **Variance** — écart moyen au carré par rapport à la moyenne
- ▶ **Écart-type** — racine carrée de la variance
- ▶ **Intervalle interquartile (IQR)** — distance entre le 25^e percentile (Q_1) et le 75^e percentile (Q_3)

Variance ou écart-type élevé → données très dispersées ; faible → données proches.

Calculer variance, écart-type et IQR

Variance :

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Écart-type :

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Intervalle interquartile (IQR) :

$$\text{IQR} = Q_3 - Q_1$$

- ▶ Q_1 (premier quartile) = médiane de la moitié inférieure
- ▶ Q_3 (troisième quartile) = médiane de la moitié supérieure

Exemple : calculer variance et écart-type

Nom	Âge
Alice	25
Bob	45
Carol	55
Dave	65
Eve	70
Fran	70

Comme précédemment, $\bar{x} = 55$.

Variance

$$\sigma^2 = \frac{(25 - 55)^2 + (45 - 55)^2 + (55 - 55)^2 + (65 - 55)^2 + (70 - 55)^2 + (70 - 55)^2}{6} = 258.33$$

Écart-type

$$\sigma = \sqrt{258.33} \approx 16.07$$

Exemple : calculer IQR

Nom	Âge
Alice	25
Bob	45
Carol	55
Dave	65
Eve	70
Fran	70

- ▶ Q_1 = médiane de la moitié inférieure (25, 45, 55) = 45
- ▶ Q_3 = médiane de la moitié supérieure (65, 70, 70) = 70

$$\text{IQR} = Q_3 - Q_1 = 70 - 45 = 25$$

Quelle mesure rapporter ?

Moyenne :

- ▶ Très standard – toujours rapporter la moyenne de vos variables
- ▶ Mais la moyenne peut être influencée par des valeurs extrêmes

Médiane :

- ▶ Non influencée par les valeurs extrêmes

Mode :

- ▶ À utiliser quand la variable prend un nombre fini de valeurs

Variance et Écart-type :

- ▶ Écart-type dans les mêmes unités que les données, variance en unités au carré

Intervalle interquartile (IQR) :

- ▶ Mesure la dispersion du milieu 50% des données
- ▶ Moins affecté par les valeurs extrêmes ou distributions asymétriques

Prochain cours...

Aujourd'hui, tout ce que nous avons vu était très **concret**

Nous avons vu des exemples de jeux de données, des méthodes pour les visualiser, et des statistiques pour les résumer

Pour approfondir nos connaissances, nous devons d'abord explorer le monde **abstrait** de la **théorie des probabilités**

La théorie des probabilités a été initialement développée pour étudier les jeux de hasard, tels que les dés, pile ou face, ou le poker

Des mathématiciens comme **Blaise Pascal** et **Pierre de Fermat** étaient fascinés par les jeux aléatoires et les ont étudiés formellement

Cela était considéré comme une trivialité jusqu'à ce que, des siècles plus tard, on découvre que cette théorie pouvait également s'appliquer à l'analyse de phénomènes réels

La semaine prochaine : nous ferons une pause avec les données et étudierons ces jeux !