

Travail pratique #1

ECO 2273
Automne 2026

Date limite : 16 octobre 2026. Remettez votre travail dans un fichier pdf par courriel aux deux adresses suivantes :

`gyetvay.sam@uqam.ca`

`djeunankan_nougan.ronald@courrier.uqam.ca`

Objet du courriel : ECO2273 + TP1 + nom de famille + code permanent

Rappel : La collaboration est autorisée (et encouragée), mais chaque étudiant doit rédiger et remettre sa propre solution. Chaque TP compte pour seulement 7,5% de votre note finale. L'objectif est d'apprendre, et non d'obtenir la « bonne » réponse. Copier un autre étudiant ou ChatGPT ne vous permettra pas d'apprendre.

Utilisation de l'IA : Je ne vais pas vous interdire d'utiliser l'IA. À mon avis, vous apprendrez mieux si vous faites de votre mieux sans y recourir. Mais si vous l'utilisez d'une façon qui vous aide à apprendre, cela me convient. Veuillez toutefois rédiger vos réponses avec vos propres mots.

Vous trouverez ce document en ligne à

www.samgyetvay.com/teaching/eco2273/tp1.pdf

Question 1 : Jeu de dés (15 points)

Sam lance deux dés, un rouge et un blanc. Considérez chaque résultat comme une paire ordonnée (dé rouge, dé blanc); il y a 36 résultats équiprobables. Définissez les événements :

- $A = \{\text{au moins un dé montre un 6}\}$
- $B = \{\text{le dé rouge montre un nombre pair}\}$
- $C = \{\text{la somme des deux nombres est paire}\}$

Question 1 (a) (4 points) Combien de résultats appartiennent à chacun des événements A , B et C ?

Question 1 (b) (7 points) Calculez $P(A)$, $P(B)$, $P(C)$, $P(A \cap B)$, $P(A \cap C)$ et $P(B \cap C)$. Quelles paires parmi A , B et C sont indépendantes? Certaines sont-elles mutuellement exclusives? Considérez maintenant $D = \{\text{le dé rouge montre un 1}\}$. D est-il mutuellement exclusif avec A , B ou C ?

Question 1 (c) (4 points) Calculez la probabilité conditionnelle $P(A | B)$.

Question 2 : Les jeunes passent-ils moins de temps avec leurs amis? (30 points)

Cette question s'inspire de l'article de John Burn-Murdoch, « Young people are hanging out less » (*Financial Times*, 18 janvier 2025).

https://www.samgyetvay.com/teaching/eco2273/jbmurdoch_ft.pdf

Question 2 (a) (3 points) Nous allons analyser des données de l'American Time Use Survey (ATUS). Lisez Hamermesh, Frazis et Stewart (2005), « Data Watch: The American Time Use Survey » :

<https://www.aeaweb.org/articles?id=10.1257/0895330053148029>

Décrivez les personnes qui participent à l'ATUS, les questions posées et la présentation des réponses dans le jeu de données. Quelles questions pourrait-on étudier avec ces données?

Question 2 (b) (4 points) Le fichier utilisé ci-dessous contient une variable appelée `weight`, créée par le BLS. Lisez l'entrée « Statistical weight » dans la documentation ATUS :

<https://www.bls.gov/tus/other-documentation/freqvariables.pdf>

Dans Stata, tapez `help weight` et lisez les entrées sur `fweight`, `aweight` et `pweight`. Expliquez ce que représente `weight`, pourquoi il faut l'utiliser et quel type de poids Stata devrait être utilisé dans les parties (c) et (d). Justifiez votre réponse.

Question 2 (c) (4 points) J'ai préparé des fichiers ATUS que vous pouvez télécharger ici :

<https://www.samgyetvay.com/teaching/eco2273/atus.html>

L'archive ZIP contient deux fichiers :

- `atus.csv` : une ligne par personne et par jour. `year` est l'année, `age` l'âge, `sex` vaut 1 pour les hommes et 2 pour les femmes, et `weight` est le poids d'enquête. `alone_all_min` compte les minutes seul parmi les activités pour lesquelles cette information est enregistrée, à partir de 2010. `free_time_min` compte les minutes consacrées aux repas, aux loisirs, aux sports ou aux activités religieuses lorsque la présence d'autres personnes est connue; `free_time_alone_min` compte les minutes seul durant ces activités. L'année 2020 est exclue.
- `atus_activities.csv` : une ligne par activité et situation de présence, pour les personnes de 18–29 ans. `alone` vaut 1 pour « seul » et 0 pour « avec d'autres ». `minutes2010` et `minutes2023` sont des minutes moyennes par personne et par jour, y compris les personnes qui n'ont pas fait l'activité. `meaningfulness` est une moyenne pondérée des évaluations du module ATUS Well-Being de 2010, 2012 et 2013.

À partir de `atus.csv`, reproduisez le premier graphique du Financial Times : un graphique linéaire des heures moyennes seul par jour selon l'âge. Mettez des groupes d'âge de trois ans (18–20, 21–23, etc., jusqu'à 75–77) sur l'axe horizontal et les heures sur l'axe vertical. Tracez deux lignes, pour 2010 et 2023, avec des couleurs et une légende différentes. Comment les heures passées seul ont-elles changé selon l'âge?

Indice : Après avoir créé les groupes d'âge, utilisez `collapse` pour calculer la moyenne de `alone_all_min` par année et groupe d'âge, avec le type de poids choisi en (b), puis divisez par 60.

Question 2 (d) (5 points) Reproduisez maintenant le deuxième graphique du Financial Times. Pour chaque année disponible de 2004 à 2022, calculez le pourcentage du temps consacré aux activités de temps libre sélectionnées qui a été passé seul. Faites une figure à six panneaux, pour les groupes 18–24, 25–34, 35–44, 45–54, 55–64 et 65 ans ou plus. Dans chaque panneau, mettez l'année sur l'axe horizontal et le pourcentage sur l'axe vertical; tracez une ligne pour les hommes et une pour les femmes, avec les mêmes couleurs et la même échelle verticale dans les six panneaux. Ajoutez une légende en bas. Comment les écarts évoluent-ils au fil du temps? Diffèrent-ils entre hommes et femmes?

Indice : Après avoir créé les six groupes d'âge, utilisez `collapse` pour calculer les moyennes de `free_time_alone_min` et de `free_time_min`, par année, sexe et groupe d'âge. Le pourcentage vaut 100 fois le rapport de ces deux moyennes. L'option `by (age_group, cols(3))` de `twoway` organise les panneaux en deux rangées. **Question 2 (e)** (4 points)

Lisez les guides du BLS sur le *Who File* et le *Well-Being Activity File* :

<https://www.bls.gov/tus/other-documentation/howto.htm>

<https://www.bls.gov/tus/questionnaires/wbmquestionnaire.pdf>

<https://www.bls.gov/tus/dictionaries/atusintcodebk0325.pdf>

Expliquez comment les deux concepts de `atus_activities.csv` sont construits. Qu'est-ce que les répondants doivent déclarer pour l'évaluation sous-jacente de `meaningfulness` et quelle est son échelle? Comment le Who File définit-il « seul » et « avec d'autres »?

Question 2 (f) (7 points) Reproduisez la dernière figure de l'article du FT, un « graphique à bulles ». À partir de `atus_activities.csv`, calculez le rapport `minutes2023/minutes2010` pour chaque ligne. Mettez `meaningfulness` sur l'axe horizontal et ce rapport sur l'axe vertical; utilisez une couleur pour les activités seul et une autre pour les activités avec d'autres. La taille des bulles doit être proportionnelle à `minutes2023`. Ajoutez une légende en bas, une ligne horizontale au rapport 1 et des étiquettes lisibles pour les principaux points, comme dans l'article. Incluez Gaming seul, TV/video seul, Relaxing seul, Eating/drinking seul, Caring for pets seul, Homework seul, Socialising avec d'autres et Playing with children avec d'autres. Comment interprétez-vous cette figure? Dans quels types d'activités les jeunes passent-ils plus de temps? Passent-ils plus de temps dans des activités « significatives »?

Indice : Dans Stata, `scatter` accepte `[aw=minutes2023]` pour faire varier la taille des bulles. Superposez deux couches avec `twoway`. Pour `alone==1`, utilisez `mcolor(cranberry)`; pour `alone==0`, `mcolor(eltblue)`. Utilisez `msymbol`, `mlabel`, `yscale(log)`, `ylabel(.5 1 2 4)` et `yline(1)`.

Question 2 (g) (3 points) Donnez votre opinion sur l'analyse. Que montrent les figures reproduites? Quelles limites ou critiques peut-on formuler?

Question 3 : Quand arrivera la prochaine demande? (25 points)

Les chauffeurs Uber à Montréal reçoivent en moyenne quatre demandes de course par heure. Dans cette question, nous simulerons le processus des demandes pour 1 000 chauffeurs Uber dans STATA et étudierons sa distribution.

Question 3 (a) (5 points) Simulez 1 000 quarts indépendants de deux heures, divisés en intervalles de 15 secondes. Les demandes arrivent indépendamment, avec une probabilité de $1/60$ par intervalle et au plus une demande par intervalle. Créez un jeu de données avec une ligne par intervalle et les variables `shift`, `interval`, `minute` et `request`. Utilisez `set seed 2273` (pourquoi?) et visualisez les demandes de dix quarts.

Indice : `runiform()` produit un nombre aléatoire entre 0 et 1. Commencez par :

```
set obs 480000
gen shift = ceil(_n/480)
bysort shift: gen interval = _n
```

Indice : `twoway scatter` peut montrer le moment des demandes pour les quarts sélectionnés. **Question 3 (b)** (4 points) Pour chaque quart, comptez les demandes durant

la *première heure*. Représentez la distribution par un histogramme et donnez quelques statistiques descriptives.

Indice : `collapse` ou `egen` peuvent créer un compte par quart; l'option `discrete` est utile dans l'histogramme.

Question 3 (c) (4 points) Simulez 1 000 tirages d'une loi de Poisson de moyenne 4. Représentez dans un même graphique cette distribution et celle simulée en (b). Commentez.

Indice : `rpoisson(4)` génère une Poisson de moyenne 4; `twoway` peut superposer les distributions.

Question 3 (d) (4 points) Pour chaque quart, calculez le temps jusqu'à la première demande. Représentez la distribution par un histogramme et donnez quelques statistiques descriptives.

Indice : `egen` ou `collapse` peuvent trouver la première demande. Réfléchissez au traitement d'un quart sans demande.

Question 3 (e) (5 points) Simulez 1 000 tirages d'une loi exponentielle de temps d'attente moyen 15 minutes. Dans les deux simulations, calculez la proportion dont l'attente dépasse 30 minutes; comparez-la à la probabilité théorique de la loi exponentielle.

Indice : `rexp(15)` génère des temps d'attente exponentiels de moyenne 15 minutes.

Question 3 (f) (3 points) À partir des demandes simulées en (a), estimez la proportion de quarts où l'attente dépasse 15 minutes, puis la proportion où elle dépasse 30 minutes *parmi les quarts dont elle dépasse déjà 15 minutes*. Comparez ces proportions. Qu'illustre cette comparaison à propos de la loi exponentielle?

Question 4 (15 points) Nous analyserons le jeu de données National Longitudinal Surveys Women (1988) avec la commande `sysuse nlsw88.dta` dans STATA.

Question 4 (a) (4 points) Faites un nuage de points de la relation entre salaire et ancienneté. Décrivez la figure. Voyez-vous une relation? Définissez une nouvelle variable, `tenure_bin`, égale à 2,5 si l'ancienneté est entre 0 et 5, 7,5 si elle est entre 5 et 10, etc. Calculez le salaire moyen dans chaque intervalle et faites un nuage de points de cette

moyenne et de `tenure_bin`. Quelle relation voyez-vous maintenant?

Question 4 (b) (4 points) Utilisez `binscatter` pour créer un graphique `binscatter` de la relation entre salaire et ancienneté. Décrivez la figure. Voyez-vous une relation? Vous devrez peut-être exécuter `ssc install binscatter`. Documentation :

<https://michaelstepner.com/binscatter/>

Question 4 (c) (4 points) Générez une variable égale au logarithme du salaire. Calculez sa corrélation avec l'ancienneté dans l'échantillon complet, puis séparément pour les femmes syndiquées et non syndiquées, mariées et non mariées, et vivant dans le Sud ou hors du Sud. Résumez et discutez vos résultats.

Question 4 (d) (3 points) Faites un histogramme de la distribution des salaires. Est-elle symétrique, ou a-t-elle une queue à droite ou à gauche? Indiquez la moyenne, l'écart-type, l'asymétrie et l'étendue interquartile dans la légende et discutez. Faites une figure contenant deux histogrammes, un pour les femmes syndiquées et un pour les femmes non syndiquées. _____

Question 5 (15 points) Nous utiliserons le jeu de données `canada.csv`, disponible à

www.samgyetvay.com/teaching/eco2273/canada.csv

Il contient le revenu moyen des ménages, la population, le taux d'urbanisation et le taux de chômage de chaque province canadienne de 1926 à 2016. Les données proviennent de Statistique Canada, tableau 36-10-0229-01 (anciennement CANSIM 384-5000).

Question 5 (a) (4 points) Y a-t-il des valeurs manquantes? Quelles variables sont manquantes pour quelles années?

Question 5 (b) (4 points) Faites des graphiques chronologiques montrant l'évolution du revenu des ménages, de l'urbanisation et du chômage pour l'ensemble du Canada. (Indice : pour créer une série canadienne, calculez une moyenne pondérée par la population provinciale.) Discutez les résultats.

Question 5 (c) (4 points) Faites des graphiques chronologiques du revenu des ménages, de la population, de l'urbanisation et du chômage au Québec et en Ontario. Pour chaque variable, faites un graphique montrant les deux provinces. Utilisez des couleurs différentes pour distinguer les provinces. Discutez les résultats.

Question 5 (d) (3 points) Calculez le taux de croissance annuel du revenu des ménages et tracez-le pour le Québec et l'Ontario dans un même graphique. Discutez les résultats.