

Problem Set #2

ECO 2273
Automne 2025

Due date: 10-oct-2025. You can submit in-person in class or by email. If you submit by email, please email to sam.gyetvay@gmail.com and djamaldiev.oumar@courrier.uqam.ca with subject ECO2273 + TP2 + your last name + student number.

Reminder: Collaboration is allowed (and encouraged) but each student must write and submit their own solution.

Instructions: please write neatly and keep your answers as short as possible. If you scan or take a photo of your solution, please make sure it is legible. For the questions involving analysis of a data set, you are free to use whichever software you like, but I recommend using STATA, as some questions on the exams will require you to interpret STATA code and output.

You can find this document online at www.samgyetvay.com/teaching/eco2273/tp2.pdf

Question 1: Cigarettes et poids à la naissance (20 points)

Une économiste de la santé a recueilli une base de données contenant des informations sur les naissances au Québec. Deux variables d'intérêt sont la variable dépendante, le poids du nouveau-né en onces (*bwght*), et une variable explicative, le nombre moyen de cigarettes que la mère a fumées par jour pendant la grossesse (*cigs*). La régression linéaire simple suivante a été estimée à partir de données sur $n = 1,388$ naissances:

$$\hat{bwght} = 119.77 - 0.514cigs$$

Question 1 (a) Quel est le poids prévu lorsque $cigs = 0$? Et lorsque $cigs = 20$? Commentez la différence.

Question 1 (b) Cette régression simple capture-t-elle nécessairement une relation causale entre le poids de naissance de l'enfant et les habitudes tabagiques de la mère? Expliquez pourquoi ou pourquoi pas.

Question 1 (c) Pour prédire un poids de 125 onces, quelle devrait être la valeur de *cigs*? Commentez.

Question 1 (d) La proportion de femmes dans l'échantillon qui ne fument pas pendant la grossesse est d'environ 0.85. Cela aide-t-il à concilier votre résultat de la partie (c)?

Question 2: Salaires des PDG (30 points)

Pour cette question, utilisez la base de données sur les salaires des PDG située à

www.samgyetvay.com/teaching/eco2273/ceo.dta

www.samgyetvay.com/teaching/eco2273/ceo.csv

la variable *salary* correspond à la rémunération annuelle, en milliers de dollars, et *ceoten* est le nombre d'années précédentes en tant que PDG de l'entreprise.

Question 2 (a) Trouvez le salaire moyen et l'ancienneté moyenne dans l'échantillon.

Question 2 (b) Combien de PDG en sont à leur première année en tant que PDG (c'est-à-dire *ceoten* = 0)? Quelle est l'ancienneté maximale comme PDG?

Question 2 (c) Estimez le modèle de régression simple

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{ceoten} + u$$

et rapportez vos résultats. Quelle est l'augmentation en pourcentage approximative du salaire associée à une année supplémentaire comme PDG? Quelle fraction de la variation du salaire est expliquée par l'ancienneté? Pouvez-vous rejeter l'hypothèse nulle selon laquelle il n'y a aucune relation entre l'ancienneté et le salaire?

Question 2 (d) Créez un nuage de points montrant la relation entre $\log(\text{salary})$ et *ceoten*, contenant la droite d'ajustement estimée à la partie (c).

Question 2 (e) Parmi les autres variables dans la base de données (*age*, *college*, *grad*, *sales*, *profits*, *prof marg*), laquelle explique la plus grande fraction de la variation du salaire des PDG?

Question 3: Simulation (50 points)

Dans cette question, vous analyserez des données que vous simulez vous-même. Dans STATA, vous pouvez simuler des données en utilisant les fonctions *runiform()* et *rnormal()*.

Question 3 (a) Commencez par générer 500 observations de x_i provenant d'une distribution uniforme sur l'intervalle $[0, 10]$. Quelle est la moyenne échantillonnale et l'écart-type échantillonnal des x_i ? Quel est l'intervalle de confiance à 95% pour la moyenne de x_i ? Contient-il la vraie moyenne?

Question 3 (b) Générez aléatoirement 500 erreurs u_i provenant de la distribution $N(0, 36)$. La moyenne échantillonnale des u_i est-elle exactement égale à zéro? Pourquoi ou pourquoi pas? Quel est l'écart-type échantillonnal des u_i ?

Question 3 (c) Maintenant, générez la variable y_i selon

$$y_i = 1 + 2x_i + u_i = \beta_0 + \beta_1 x_i + u_i$$

c'est-à-dire que l'ordonnée à l'origine dans la population est égale à un et la pente dans la population est égale à deux. Utilisez les données pour estimer la régression de y_i sur x_i . Quelles sont vos estimations de l'ordonnée à l'origine et de la pente? Sont-elles égales aux valeurs de population dans l'équation ci-dessus? Expliquez.

Question 3 (d) Obtenez les résidus MCO $\hat{u}_i$ et vérifiez que

$$\sum_{i=1}^n \hat{u}_i = 0, \quad \text{et} \quad \sum_{i=1}^n x_i \hat{u}_i = 0$$

Question 3 (e) Calculez les mêmes quantités qu'à la partie (d) mais utilisez les erreurs u_i à la place des résidus. Que concluez-vous maintenant?

Question 3 (f) Répétez les parties (a), (b) et (c) avec un nouvel échantillon de données, en recommençant par générer les x_i . Que trouvez-vous maintenant pour β_0 et β_1 ? Sont-ils différents de ce que vous avez obtenu à la partie (c)? Si oui, pourquoi? Sinon, pourquoi pas?