

La sélection et le modèle de Roy

Sam Gyetvay

ECO8000

September 8, 2025

Sélection

Idée omniprésente en théorie économique : les individus font des choix basés sur un comportement d'optimisation

- ▶ Choisir l'emploi qui offre le salaire le plus élevé

Pourquoi les gens font-ils des choix différents ?

- ▶ Les avocats sont mieux payés que les économistes
- ▶ Pourquoi tous les économistes ne deviennent-ils pas avocats ?
- ▶ Avons-nous fait une erreur ?

Les individus sont différents

- ▶ Ceux qui choisissent d'être économistes sont bons en maths et aiment coder
- ▶ Ceux qui choisissent d'être avocats sont bons en lecture et aiment débattre
- ▶ Certains économistes seraient de mauvais avocats, et inversement...

Pourquoi est-ce important ?

Il existe de grandes différences de revenus entre groupes de travailleurs

- ▶ Les travailleurs en milieu rural gagnent moins que ceux en ville
- ▶ Les travailleurs avec un bac gagnent plus que ceux avec un diplôme de CÉGEP
- ▶ Les travailleurs dans des entreprises syndiquées gagnent plus que ceux dans des entreprises non syndiquées

Pourrait-on réduire les inégalités salariales en déplaçant les travailleurs ruraux vers les villes, en obligeant tous les étudiants de CÉGEP à obtenir un baccalauréat, et en transférant tous les travailleurs non syndiqués vers des entreprises syndiquées ?

Si les différences sont causées par la sélection, ces politiques *augmenteraient* les inégalités !

- ▶ Les travailleurs ont choisi rural/CÉGEP/non-syndiqué parce qu'ils gagnaient un salaire plus élevé que s'ils étaient urbains/universitaires/syndiqués

SOME THOUGHTS ON THE DISTRIBUTION OF EARNINGS¹

By A. D. ROY

I

AN attempt has been made elsewhere² to show that the output of any individual working by hand is the resultant of a large number of random influences. As a first approximation these influences can be assumed to operate independently, i.e. they are not significantly associated with one another. The rather vague term 'influence' is intended to refer to such factors as health, strength, skill, and so on. The suggestion was made that it is more fruitful to define such factors so that, taken singly, they exercise the same proportionate effect on the output of otherwise similarly situated individuals rather than the same absolute effect. In other words, it is more reasonable to say that a given loss of health will depress a worker's output by, say, 10 per cent., other things being equal, than by, say, 10 units.

Modèle de Roy

Le modèle de Roy nous fournit un cadre qui permet d'analyser la sélection

Il produit des prédictions puissantes reliant la distribution des compétences à la nature de la sélection

- ▶ Comment la dispersion des compétences affecte-t-elle la sélection ?
- ▶ Comment la corrélation entre différentes compétences affecte-t-elle la sélection ?

Questions clés en économie du travail :

- ▶ Les travailleurs qui choisissent d'immigrer sont-ils plus productifs que ceux qui choisissent de rester dans leur pays d'origine ?
- ▶ Les femmes qui choisissent de travailler sont-elles plus productives sur le marché du travail que celles qui n'y entrent pas ?

Plan

1. Motivation # 1 : assimilation salariale des immigrants
2. Motivation # 2 : offre de travail féminine et écart salarial entre les sexes
3. Modèle de Roy : chasse et pêche
4. Modèle linéaire normal de Roy
5. Borjas (1987)
6. Mulligan et Rubinstein (2008)
7. Discussion: **Abramitzky, Boustan et Eriksson (2012)**

Motivation #1 : assimilation salariale des immigrants

Les immigrants sont moins bien payés que les natifs comparables à leur arrivée. Leurs salaires rattrapent-ils ceux des natifs à mesure qu'ils accumulent de l'expérience dans le nouveau pays ? Si oui, à quelle vitesse ?

Chiswick (1978) a tenté de répondre à cette question avec des données du recensement américain de 1970.

Le recensement de 1970 est une **coupe transversale unique** (anglais: **single cross-section**). Il enregistre un « instantané » des individus à un moment donné.

Le jeu de données compilé par Chiswick ressemblait à ceci :

ID	Immigrant	AnnéesDepuisImmig	Expérience	Revenu	Éducation
1	Oui	2	5	18,000	<HS
2	Non	-	12	25,000	HS
3	Oui	10	15	32,000	CÉGEP
4	Non	-	20	40,000	Bac
5	Oui	25	30	45,000	Bac

Chiswick (1978)

Chiswick a estimé la régression suivante

$$\log(\text{Revenu}_i) = X_i' \theta + \beta \text{Exp}_i + \delta \text{Imm}_i + \alpha \text{YSM} \times \text{Imm}_i + \epsilon_i$$

et a obtenu $\hat{\beta} = 0.03$, $\hat{\delta} = -0.2$, et $\hat{\alpha} = 0.01$.

Comment interpréter ces coefficients ?

Chiswick (1978)

Chiswick a estimé la régression suivante

$$\log(\text{Revenu}_i) = X_i'\theta + \beta \text{Exp}_i + \delta \text{Imm}_i + \alpha \text{YSM} \times \text{Imm}_i + \epsilon_i$$

et a obtenu $\hat{\beta} = 0.03$, $\hat{\delta} = -0.2$, et $\hat{\alpha} = 0.01$.

Comment interpréter ces coefficients ?

- β : effet d'une année d'expérience supplémentaire sur le revenu logarithmique des natifs (+1 an $\rightarrow$ +3% de revenu)

Chiswick (1978)

Chiswick a estimé la régression suivante

$$\log(\text{Revenu}_i) = X_i' \theta + \beta \text{Exp}_i + \delta \text{Imm}_i + \alpha \text{YSM} \times \text{Imm}_i + \epsilon_i$$

et a obtenu $\hat{\beta} = 0.03$, $\hat{\delta} = -0.2$, et $\hat{\alpha} = 0.01$.

Comment interpréter ces coefficients ?

- ▶ β : effet d'une année d'expérience supplémentaire sur le revenu logarithmique des natifs (+1 an $\rightarrow$ +3% de revenu)
- ▶ δ : différence de revenu logarithmique entre immigrants et natifs à l'arrivée (20% de moins)

Chiswick (1978)

Chiswick a estimé la régression suivante

$$\log(\text{Revenu}_i) = X_i'\theta + \beta \text{Exp}_i + \delta \text{Imm}_i + \alpha \text{YSM} \times \text{Imm}_i + \epsilon_i$$

et a obtenu $\hat{\beta} = 0.03$, $\hat{\delta} = -0.2$, et $\hat{\alpha} = 0.01$.

Comment interpréter ces coefficients ?

- ▶ β : effet d'une année d'expérience supplémentaire sur le revenu logarithmique des natifs (+1 an $\rightarrow$ +3% de revenu)
- ▶ δ : différence de revenu logarithmique entre immigrants et natifs à l'arrivée (20% de moins)
- ▶ α : effet d'une année supplémentaire depuis l'immigration sur le revenu logarithmique des immigrants (+1 an $\rightarrow$ +1% de revenu)

Comme chaque année depuis l'immigration apporte aussi une année d'expérience supplémentaire, les revenus des immigrants augmentent 1% plus vite que ceux des natifs.

(Question bonus : combien de temps avant qu'ils rattrapent ?)

Borjas c. Chiswick


Dans un article de 1985, George Borjas a critiqué la conclusion de Chiswick.

Dans la régression de Chiswick, le coefficient sur les années depuis l'immigration (α) reflète une combinaison de deux effets :

1. Effet réel d'assimilation salariale
2. Différences de productivité fixes entre cohortes

Comme on n'observe qu'un seul « instantané » de chaque cohorte à un moment donné, on ne peut pas distinguer ces deux effets.

Si la productivité des cohortes d'immigrants décline au fil du temps, cela conduirait à une surestimation de l'assimilation.



Borjas (1985)

Borjas a combiné les recensements de 1970 et 1980 pour créer un ensemble de données en **coupures transversales répétées** (anglais: **repeat cross-section**).

Cela lui permet d'observer les membres d'une même cohorte d'immigrants à deux périodes différentes. Il peut ainsi estimer des valeurs distinctes de δ pour chaque cohorte :

$$\log(\text{Revenu}_{it}) = X_i' \theta_t + \beta \text{Exp}_i + \delta_c \text{Imm}_i + \alpha \text{YSM} \times \text{Imm}_i + \epsilon_{it}$$

En effet, Borjas a montré que Chiswick surestimait fortement la croissance des revenus des immigrants, et que les valeurs de δ_c pour les cohortes plus récentes déclinaient.

Dans sa conclusion, Borjas avance des hypothèses sur la raison du déclin des revenus initiaux des cohortes successives d'immigrants :

*Bien qu'une partie puisse être expliquée par une baisse de la demande de main-d'œuvre immigrée, les résultats sont compatibles avec l'hypothèse d'un **déclin séculaire de la qualité des cohortes d'immigrants**.*

...mais qu'est-ce qui a causé ce déclin de la « qualité » (productivité) des immigrants ?

Borjas (1987)

Dans un article subséquent dans l'American Economic Review, Borjas propose une réponse simple et convaincante : la sélection.

Les immigrants ne sont pas un échantillon aléatoire de la population mondiale. Pour immigrer, il faut d'abord choisir de le faire. Pourquoi certains choisissent-ils et pas d'autres ? Comment les candidats à l'immigration décident-ils ?

Borjas :

On suppose que les individus comparent leurs revenus potentiels aux États-Unis avec leurs revenus dans leur pays d'origine, et prennent leur décision de migrer en fonction de ces différentiels (nets des coûts de mobilité).

Cette citation résume l'essence du modèle de Roy.

Comment la sélection peut-elle expliquer l'évolution de la qualité entre cohortes d'immigrants ?

Avant de voir l'argument de Borjas, il nous faut maîtriser le modèle de Roy.

Mais d'abord, une autre motivation...

Motivation #2 : écart salarial entre les sexes




FIGURE 7. WOMEN'S EARNINGS AS A PERCENTAGE OF MEN'S EARNINGS: 1960 TO 2003

Participation au marché du travail selon le sexe (Goldin, 2006)




FIGURE 1. LABOR FORCE PARTICIPATION RATES FOR FEMALES AND MALES BY AGE AND MARITAL STATUS: 1890 TO 2004

Sélection et écart salarial entre les sexes

L'écart salarial entre hommes et femmes s'est réduit depuis les années 1960. Cependant, la proportion de femmes dans la population active a aussi beaucoup augmenté pendant cette période.

On n'observe que les revenus des femmes qui travaillent, mais on s'intéresse aussi aux salaires potentiels des femmes qui ne travaillent pas.

Si, dans les années 1960, ce sont surtout les femmes à haut salaire potentiel qui choisissaient de ne pas travailler, alors la baisse de l'écart salarial pourrait être due uniquement à la sélection, et non à une rémunération plus équitable.


On peut utiliser la régression linéaire pour contrôler certaines différences observables. Mais les ensembles de données n'incluent que quelques variables (âge, éducation), et les compétences non observées expliquent une grande partie des écarts de revenu.

La quasi-totalité des hommes en âge actif travaillent, donc le « biais de sélection » nous préoccupe moins pour eux.

Gronau (1974)

*Plus de 95 pour cent des hommes en âge actif (25-55) participent au marché du travail, alors que le taux de participation des femmes, en particulier des femmes mariées, dépasse rarement 55 pour cent. **La différence de participation peut être expliquée par la distribution plus faible des offres de salaires auxquelles font face les femmes**, et probablement par la valeur plus élevée de leur temps en l'absence d'opportunités de marché. Ces deux facteurs tendent à **accroître l'écart entre le salaire minimum acceptable et le salaire moyen offert.***

*On a estimé que le salaire horaire moyen des femmes, ajusté pour [race], scolarité, taille de la ville, statut marital, catégorie professionnelle et durée du trajet, représentait en 1959 seulement les deux tiers de celui des hommes hors agriculture. **Étant donné le « biais de sélection », il semble que ce chiffre sous-estime l'écart salarial « réel » entre hommes et femmes.***



+ Female + Male

Coïncidence ?

Axe Y = écart salarial femmes, Axe X = inégalités parmi les hommes




Figure 1 Wage Inequality between and within Genders

... pensez-y :-)

Le monde de Roy

Nous entrons maintenant dans le monde du modèle de Roy.

Dans le monde de Roy, nous supposons :

- ▶ Les travailleurs sont très différents de façon inobservable
- ▶ Les salaires ne changent pas et chacun obtient son emploi préféré
- ▶ Pas de « chance »
- ▶ Pas de chômage

Dans le monde de Roy, il n'y a que deux professions : chasseur de lapins et pêcheur.

Mise en place

- ▶ R : chasse (aux lapins)
- ▶ F : pêche (aux poissons)
- ▶ π_R : prix des lapins
- ▶ π_F : prix des poissons
- ▶ R_i : nombre de lapins attrapés par le travailleur i
- ▶ F_i : nombre de poissons attrapés par le travailleur i
- ▶ $w_{Ri} = \pi_R R_i$: salaire que i reçoit s'il choisit la chasse
- ▶ $w_{Fi} = \pi_F F_i$: salaire que i reçoit s'il choisit la pêche
- ▶ $\log w_{Ri} = \log \pi_R + \log R_i$
- ▶ $\log w_{Fi} = \log \pi_F + \log F_i$

Pour simplifier, $\log \pi_R = \log \pi_F = 0$

Direction de la sélection

Les chasseurs sont-ils meilleurs à la pêche que les pêcheurs ?


- ▶ Si oui, **sélection positive dans la chasse**

Les pêcheurs sont-ils moins bons à la chasse que les chasseurs ?

- ▶ Si oui, **sélection négative dans la pêche**


Sinon, pas de sélection dans la chasse/pêche

Qui chasse, qui pêche?




Cas 1 : seulement une variance dans la capacité de pêche

Selection: +F, 0R




Cas 2a : $\log R_i = \alpha_0 + \alpha_1 \log F_i$, $\alpha_1 > 1$

Sélection: -F, +R




Cas 2b : $\log R_i = \alpha_0 + \alpha_1 \log F_i$, $\alpha_1 < 1$

Sélection: +F, -R



Cas 3 : corrélation négative

Sélection: +F, +R



Modèle de Roy linéaire normal

$$\begin{bmatrix} \log F_i \\ \log R_i \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_F \\ \mu_R \end{bmatrix}, \begin{bmatrix} \sigma_{FF}^2 & \sigma_{RF} \\ \sigma_{RF} & \sigma_{RR}^2 \end{bmatrix} \right)$$

- ▶ μ_F : capacité moyenne de pêche
- ▶ μ_R : capacité moyenne de chasse
- ▶ σ_{FF} : écart-type de la capacité de pêche
- ▶ σ_{RR} : écart-type de la capacité de chasse
- ▶ $\frac{\sigma_{RF}}{\sqrt{\sigma_{FF}\sigma_{RR}}}$: corrélation entre capacité de chasse et de pêche

Pour simplifier l'algèbre, nous supposons $\log(\pi_R) = \log(\pi_F) = 0$

Rappel sur la loi normale

Entièrement décrite par ses deux premiers moments (moyenne et variance)

$X \sim N(\mu, \sigma^2)$ signifie « X suit une loi normale de moyenne μ et de variance σ^2 »

Densité $f(X) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(X-\mu)^2}{2\sigma^2}\right)$

$\mu = E[X] = \int_{-\infty}^{\infty} xf(x)dx$, $\sigma^2 = Var[X] = E[(X - \mu)^2]$

Si $X \sim N(\mu, \sigma^2)$, alors $aX + b \sim N(a\mu + b, b^2\sigma^2)$.

Si $X_1 \sim N(\mu_1, \sigma_1^2)$ et $X_2 \sim N(\mu_2, \sigma_2^2)$ sont indépendants, alors $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

La loi normale standard $Z \sim N(0, 1)$ a un symbole spécial pour sa densité $\phi(\cdot)$ et sa fonction de répartition (anglais: CDF) $\Phi(\cdot)$

Rapport de Mills inverse (anglais: Inverse Mills Ratio)

Si $X \sim N(\mu, \sigma^2)$, alors

$$\begin{aligned}\mathbb{E}[X \mid X > a] &= \mu + \sigma \frac{\phi\left(\frac{a-\mu}{\sigma}\right)}{1 - \Phi\left(\frac{a-\mu}{\sigma}\right)} \\ &= \mu + \sigma \lambda\left(\frac{a-\mu}{\sigma}\right)\end{aligned}$$

$\lambda(\cdot) = \frac{\phi(\cdot)}{1-\Phi(\cdot)}$ est appelé le **rapport de Mills inverse**

Rappel sur la loi normale bvariée


$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right)$$

en mots : « X_1 et X_2 suivent une loi normale conjointe »


- ▶ $X_1 \sim N(\mu_1, \sigma_1^2)$
- ▶ $X_2 \sim N(\mu_2, \sigma_2^2)$
- ▶ $\text{Cov}(X_1, X_2) = \sigma_{12}$

$$X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12})$$


Si X_1 et X_2 sont conjointement normaux, toute combinaison linéaire $Y_1 = aX_1 + bX_2$ et $Y_2 = cX_1 + dX_2$ est aussi conjointe normale.




$$\sigma_x = \sigma_y, \rho = 0$$




$$2\sigma_x = \sigma_y, \rho = 0$$




$$\sigma_x = \sigma_y, \rho = 0.75$$




$$2\sigma_x = \sigma_y, \rho = 0.75$$



$$\sigma_x = \sigma_y, \rho = -0.75$$



$$2\sigma_x = \sigma_y, \rho = -0.75$$



Espérance conditionnelle de normales conjointes

Si $\begin{bmatrix} X \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{bmatrix} \right)$, alors :

$$\mathbb{E}[Y | X] = \mu_Y + \frac{\sigma_{XY}}{\sigma_X^2}(X - \mu_X).$$

Preuve : On peut écrire $Y = \alpha_0 + \alpha_1 X + U$ où U est normal, de moyenne nulle et indépendant de X .

$$\text{Cov}(Y, X) = \text{Cov}(\alpha_0 + \alpha_1 X + U, X)$$

$$\sigma_{XY} = \alpha_1 \text{Var}(X)$$

$$\alpha_1 = \sigma_{XY} / \sigma_X^2$$

$$\mathbb{E}[Y] = \mathbb{E}[\alpha_0 + \alpha_1 X + U]$$

$$= \alpha_0 + \alpha_1 \mu_X$$

$$\alpha_0 = \mu_Y - \alpha_1 \mu_X$$

En combinant les deux,

$$\mathbb{E}[Y | X] = \mu_Y - \alpha_1 \mu_X + \alpha_1 X = \mu_Y + \alpha_1 (X - \mu_X).$$



Retour au modèle de Roy linéaire normal

Le travailleur i choisit de chasser si $\log(R_i) > \log(F_i)$.

$$E[\log R_i | \log R_i > \log F_i]$$

Qu'est-ce que c'est ?

Retour au modèle de Roy linéaire normal

Le travailleur i choisit de chasser si $\log(R_i) > \log(F_i)$.

$$E[\log R_i | \log R_i > \log F_i]$$

Qu'est-ce que c'est ? → **Capacité moyenne de chasse des travailleurs qui choisissent de chasser**

Retour au modèle de Roy linéaire normal

Le travailleur i choisit de chasser si $\log(R_i) > \log(F_i)$.

$$E[\log R_i | \log R_i > \log F_i]$$

Qu'est-ce que c'est ? → **Capacité moyenne de chasse des travailleurs qui choisissent de chasser**

$$E[\log R_i]$$

Et ça ?

Retour au modèle de Roy linéaire normal

Le travailleur i choisit de chasser si $\log(R_i) > \log(F_i)$.

$$E[\log R_i | \log R_i > \log F_i]$$

Qu'est-ce que c'est ? → **Capacité moyenne de chasse des travailleurs qui choisissent de chasser**

$$E[\log R_i]$$

Et ça ? → **Capacité moyenne de chasse de tous les travailleurs** (y compris ceux qui ne choisissent pas de chasser)

Retour au modèle de Roy linéaire normal

Le travailleur i choisit de chasser si $\log(R_i) > \log(F_i)$.

$$E[\log R_i | \log R_i > \log F_i]$$

Qu'est-ce que c'est ? → **Capacité moyenne de chasse des travailleurs qui choisissent de chasser**

$$E[\log R_i]$$

Et ça ? → **Capacité moyenne de chasse de tous les travailleurs** (y compris ceux qui ne choisissent pas de chasser)

Si $E[\log R_i | \log R_i > \log F_i] > E[\log R_i]$, alors il y a

(a) positive

(b) négative

(c) aucune

sélection dans la chasse.

Retour au modèle de Roy linéaire normal

Le travailleur i choisit de chasser si $\log(R_i) > \log(F_i)$.

$$E[\log R_i | \log R_i > \log F_i]$$

Qu'est-ce que c'est ? → **Capacité moyenne de chasse des travailleurs qui choisissent de chasser**

$$E[\log R_i]$$

Et ça ? → **Capacité moyenne de chasse de tous les travailleurs** (y compris ceux qui ne choisissent pas de chasser)

Si $E[\log R_i | \log R_i > \log F_i] > E[\log R_i]$, alors il y a

(a) **positive**

~~(b) négative~~

~~(c) aucune~~

sélection dans la chasse.

Combien de travailleurs choisissent la chasse ?

La différence entre la capacité de chasse et de pêche du travailleur i est

$$\log R_i - \log F_i \sim N(\mu_R - \mu_F, \sigma^2).$$

Alors la part des travailleurs qui chassent est :

$$\begin{aligned} P(\text{travailleur } i \text{ chasse}) &= P(\log R_i - \log F_i > 0) \\ &= P\left(\frac{\log R_i - \log F_i}{\sigma} > 0\right) \\ &= P\left(\underbrace{\frac{\log R_i - \log F_i - (\mu_R - \mu_F)}{\sigma}}_{\sim N(0,1)} > \frac{\mu_F - \mu_R}{\sigma}\right) \\ &= \Phi\left(\frac{\mu_R - \mu_F}{\sigma}\right) \end{aligned}$$

La part des travailleurs qui chassent augmente avec μ_R et diminue avec μ_F

Dérivation du salaire des chasseurs

Notre objectif est de dériver $E[\log R_i | \log R_i - \log F_i > 0]$ comme fonction des paramètres.

Nous procédons en deux étapes.

Étape 1 : Inverse Mills Ratio

$$E[\log R_i - \log F_i | \log R_i - \log F_i > 0] = \mu_R - \mu_F + \sigma \lambda\left(\frac{\mu_F - \mu_R}{\sigma}\right)$$

Étape 2 : l'espérance conditionnelle

$$E[\log R_i | \log R_i - \log F_i] = \mu_R + \frac{\sigma_R^2 - \sigma_{RF}}{\sigma^2} [(\log R_i - \log F_i) - (\mu_R - \mu_F)]$$

appliquer maintenant l'Étape 1 :

$$E[\log R_i | \log R_i - \log F_i > 0] = \mu_R + \frac{\sigma_R^2 - \sigma_{RF}}{\sigma^2} \lambda\left(\frac{\mu_F - \mu_R}{\sigma}\right)$$

Sélection

Réarranger

$$E[\log R_i \mid \log R_i - \log F_i > 0] - E[\log R_i] = \underbrace{\frac{\sigma_F \sigma_R}{\sigma}}_{\geq 0} \cdot \left(\frac{\sigma_R}{\sigma_F} - \rho \right) \cdot \underbrace{\lambda \left(\frac{\mu_F - \mu_R}{\sigma} \right)}_{\geq 0}$$

Le premier et le troisième terme du produit sont non négatifs, donc la sélection est déterminée par le deuxième terme.

$-1 < \rho < 1$ (pourquoi ?), donc si $\sigma_R > \sigma_F$, alors il doit y avoir une sélection positive dans la chasse !


Si $\sigma_R < \sigma_F$ et ρ est légèrement positif, il peut encore y avoir une sélection positive dans la chasse

Si $\sigma_R < \sigma_F$ et ρ est fortement positif, il y a une sélection négative dans la chasse

Si $\rho < 0$, il y a une sélection positive à la fois dans la chasse et la pêche !


Cas 1 : seulement une variance dans la capacité de pêche

$\sigma_R = 0, \sigma_F > 0, \rho = 0 \implies$ pas de sélection dans la chasse, sélection positive dans la pêche




Cas 2a : $\log R_i = \alpha_0 + \alpha_1 \log F_i$, $\alpha_1 > 1$

$\sigma_R > \sigma_F$, $\rho \approx 1 \implies$ sélection positive dans la chasse, sélection négative dans la pêche




Cas 2b : $\log R_i = \alpha_0 + \alpha_1 \log F_i$, $\alpha_1 < 1$

$\sigma_R < \sigma_F$, $\rho \approx 1 \implies$ sélection positive dans la pêche, sélection négative dans la chasse



Cas 3 : corrélation négative

$\sigma_R = \sigma_F, \rho = -1 \implies$ sélection positive dans la pêche et la chasse



La semaine prochaine

Comment estimer empiriquement le modèle de Roy à partir de données

- ▶ Méthode en deux étapes (two-step) de Heckman (« Heckit »)
- ▶ Identification non paramétrique (« identification at infinity »)

Deux applications classiques :

1. Borjas (1987) : la sélection explique-t-elle l'assimilation salariale des immigrants ?
2. Mulligan et Rubinstein (2008) : la sélection explique-t-elle le déclin de l'écart salarial entre hommes et femmes ?

Discussion en classe : **Abramitzky, Boustan et Eriksson (2012)**

- ▶ Lisez l'article pour le cours de la semaine prochaine, venez préparés à discuter